

정확한 분리수거에 용이한 쓰레기 분류기 (Classification of trash using correct recycling)

류제인, 이재훈, 백승민

¹Department of Electronics and Information Engineering, Korea University

¹first.author@first-third.edu

³third.author@first-third.edu

요약

Abstract— 본 연구는, 이미지를 식별하고 어떤 종류인지 판별하는데에 딥러닝 기술(yolov5)을 이용하였다. 직접 수집한 data를 모델에 적용 시키기 위해, labeling 작업을 거쳤으며 이를 쓰레기 분류에 적용함으로써, 실제 사용자들이 재활용 쓰레기 분류를 용이하게 돕는다.

Keywords— Yolov5, Classification, Trash, Recycling, Bounding Box, Labeling

I. INTRODUCTION

분리수거를 할 때, 어려움을 겪는 사람들이 많다. 쓰레기의 종류에 따라 종이와 플라스틱이 붙어 있거나, 알루미늄과 철의 혼합으로 이루어진 쓰레기 등. 사람들이 잘 분리하지 못하면, 분리업체나 지자체 등으로 쓰레기가 모였을 때, 재활용을 하기 위해 분리하는데 필요한 시간이나 노동력이 증가한다. 이를 근본적으로 해결하기 위해, 쓰레기를 버리는 시점부터 좋은 분류를 이끌어내기 위한 딥러닝을 구현하여 도움을 주었다. Yolov5 모델을 이용하였으며 이는, 물체 인식과 판별에 용이한 딥러닝 모델이다.

해당 주제에 대해 다양한 연구들이 국내에도 많이 진행되었는데, 한국기술교육대학교의 경우, 플라스틱 분리배출 마크를 식별해 플라스틱의 성분에 따른 분류를 하는 예시가 있다. 이는 분리된 플라스틱이 모였을 때, 더 깊은 클래스로 나누어 분류하는 것이며,

이번 연구는 큰 틀에서의 분리수거를 용이하게 하여, 크게 종이, 캔, 유리, 플라스틱으로 나누어 분류를 돕게 된다.

II. METHOD

A. Data collection and processing

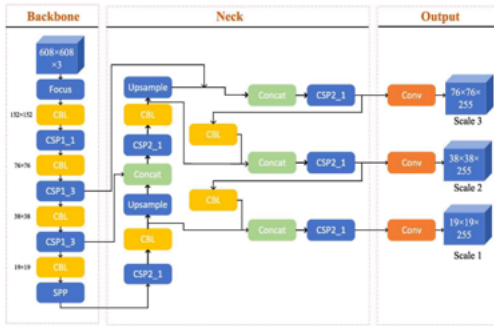
쓰레기 분류 연구를 하기 위해, 먼저 data-set을 구성하였다. 직접 촬영한 사진들과 AI 허브, Kaggle 등에서 이미지 데이터를 수집하였는데, 실사용이 될 때에는 배경이 깔끔하지 않은 경우가 많을 것이다. 따라서, 배경이 풍부한 현실감 있는 데이터 위주로 수집하였으며, 서로 다른 종류의 재질이지만 육안으로는 구분이 힘들게 생김새가 비슷한 데이터도 고려하여 수집하였다.

Yolov5 모델에 적용시키기 위해서는 수집한 데이터를 깃허브에서 제공하는 ‘Label img tool’을 이용하여 직접 labeling 하는 전처리 과정을 거치는 과정을 거쳤다.

결과적으로 각 클래스(종이, 캔, 유리, 플라스틱) 당 train data로 800 장씩, validation data 200 장으로 총 1000 장씩 학습시켰으며, test data는 각 class 당 100 장씩 이용하였다.

B. Used Model

Yolo tool을 모델로 사용하였으며, 이는 아래 세가지로 구성되어 있으며, 역할은 다음과 같다.







(1)Backbone : 이미지의 특징 추출한다.

(2)Neck : 추출된 특징 맵을 조정하고 다양한 크기와 해상도의 객체를 감지할 수 있도록 준비한다.

(3)Head : 객체 식별, 경계상자, 클래스 예측

이 yolov5 은 여러 버전이 있는데,

			
Small YOLOv5s	Medium YOLOv5m	Large YOLOv5l	XLarge YOLOv5x
14 MB _{FP16} 2.2 ms _{V100} 36.8 mAP _{COCO}	41 MB _{FP16} 2.9 ms _{V100} 44.5 mAP _{COCO}	90 MB _{FP16} 3.8 ms _{V100} 48.1 mAP _{COCO}	168 MB _{FP16} 6.0 ms _{V100} 50.1 mAP _{COCO}

s 에서 x 로 갈수록 성능이 좋아지지만, 속도가 느려지는 일종의 ‘Trade-off’가 있다.

이번 연구는 수집한 데이터에 적합한 모델 설정을 위해 실험을 반복 진행 후 5s 로 결정하였다.

해당 모델에서, hyper parameter 로는 Fine-tuning 한 weight 를 진행하였고, img-size 는 640x640 을 설정하였다. (이는 yolov5s 가 학습시 해당 img_size 를 가장 잘 인식하기 때문이다.)


Batch-size 또한 실험 환경의 메모리 용량에 맞춘 최적의 값으로 32 를 설정하였다.

Epoch 은 처음엔 300 을 시작으로, 오버피팅이 일어나면, 에폭을 낮추는 과정을 거쳤으며, 결과가 괜찮을때는 epoch 을 늘려보는 과정을 거쳐 가장 좋은 시도로 최종 50epochs 을 설정하였다. 이후에는 hyper parameter 를 고정하며, epoch 의 변화로 가장 큰 특이점을 보이는 50 과 200 의 모델을 사용하여 결과를 비교한다.

III. RESULTS

다른 hyper parameter 는 동일하며, 크게 epoch 200 과 50 을 비교하게 된다.


[1] epoch 200



Box_loss 와 Object_loss, Class_loss 를 나타낸 그래프이다. Train data 에 대한 결과는 셋 다 loss 가 작아지며 학습을 한다.


Validation data 에 대한 결과는 box_loss 는 loss 가 줄어들어 일정지점에서 saturation 이 되었다.

Object_loss 와 class_loss 의 그래프를 보면, loss 가 증가한다.



Precision 과 recall mAP 를 평가한 결과이다.

1 에 가까운 숫자로 결과가 saturation 되었다.




Confusion matrix 를 plot 한 결과이며, 가장 높은 값의 class 는 paper(0.91)이며, 가장 낮은 값의 class 는 glass(0.80)이다.




위는 test data 를 이용하여 실제 분류를 한 결과이며, 빨간색으로 labeling 된 플라스틱 쓰레기의 경우, paper 로 잘못 인식한 경우가 나타난다. 또한, 썬크림통의 경우도 glass 라고 잘못 인식한 경우가 나타난다.


[2] epoch 50



Train data 에 대한 그래프는 셋 다 loss 가 작은 방향으로 학습하는 모양이다. Validation data 에 대한 결과는 box_loss 와 object_loss 는 loss 값이 줄어들어 일정지점에서 saturation 이 되고, class_loss 의 그래프를 보면, loss 가 oscillation 이 되며 증가하는 모양이다.



Precision 과 recall mAP 를 평가한 결과이다. 1 에 가까운 숫자로 결과가 saturation 되었다.



Epoch 50 일때의 confusion matrix 를 보면, 가장 높은 값의 class 는 can 이다.



위는 epoch 이 50 일때의 model 을 이용하여 test data 로 성능을 평가해본 결과이다. 플라스틱을 paper 로 평가하였고, 썬크림을 glass 로 평가하는 오류가 발생하였다.

IV. DISCUSSION AND CONCLUSION

Yolov5s 를 이용하여, 실제 쓰레기 사진을 학습시키고, validation loss 를 이용하여 평가하였다. loss 그래프 비교를 하면, epoch 이 50 일때와 200 일 때 모두 box 와 object 는 loss 가 잘 saturation 해 가지만, class 는 oscillation 하며 성능이 조금 떨어지는 모습을 보인다. 이에 대해, 사진을 보며 직접 feature extration 을 생각해 보았고, 이는 물건마다 생김새가 다양하고, 사진만으로는 물체의 재질을 판단하는 것이 어려울 것이라 여겨진다. 또한, epoch 200 의

경우, object_loss 가 epoch 80 정도 이후부터 overfitting 이 되었기에, epoch 50 으로 진행해본 결과, best model 을 찾았다. Confusion Matrix 를 각각 plot 해 본 결과를 분석하면, 가장 높은 값을 가지는 class 가 분류가 잘 된 class 이며, 가장 낮은 값을 가지는 class 는 분류가 잘 될 확률이 낮다. 이를 토대로 Paper 기준으로는 Epoch 이 200 일때보다 50 에서 성능이 줄어듦을 볼 수 있다. 또한, glass 의 경우 epoch 50 이 200 보다 성능이 좋았다.

성능을 더 높이기 위해 문제점을 분석하고 노력했던 개선사항들은 아래와 같다.

우선, 데이터셋에 대해 labeling 이 정확하게 이루어져야 한다. 또한, 같은 종류의 물체라도 모양이 다른 경우 예측이 잘 안되는 경우가 많았기에, 더욱 다양한 종류의 폐기물 사진을 학습시키는 것이 도움이 된다.

배경(background)가 없는 이미지만 학습시켰을 경우, 배경이 있는 사진을 test 하게 되면 성능이 좋지 않았지만, 탐지할 물체가 너무 많은 경우 오히려 학습에 혼동을 줄 수 있었다. 따라서, 물체는 많지 않으나, 배경으로 인식할만한 (ex.아스팔트, 일반 도로)등의 배경위의 물체가 있는 사진과 탐지할 물체가 없는 background 이미지를 추가하여, 배경과 물체의 혼동을 줄였다.

최적의 parameter 를 찾기 위해 epoch 과 batch_size, weight, image resize, learning rate 등을 변경해가며 optimal 한 값을 찾는 것이 중요하다.

이미지 내의 작은 크기의 폐기물이 많은 경우, 원본 이미지의 높은 해상도를 사용하는 것이 도움이 되었다.

이번 연구는, 물체를 인식하고 class 를 나눠 분류하는데 용이하게 쓰인다. 따라서, 쓰레기 분류 뿐 아니라, 이미지를 이용해 분류하는 다양한 주제에 사용될 수 있을 것이다. 특히나, 재질로 판별이 되는 것 보다는 사진 속 물체의 ‘모양’으로 판단되는 연구에 도움이 될 것이다.

REFERENCES

[1] Yong jun Kim, Taeuk Cho, Hyung-kun Park
“YOLO Based Automatic Sorting System for Plastic Recycling” KOREATECH, 2021

[CFKO202132348466219.pdf \(koreascience.kr\)](#)

[2] Lunabot87, “YOLO V5 환경 셋팅 및 모델
아키텍처 분석하기”, 2020

[CFKO202132348466219.pdf \(koreascience.kr\)](#)